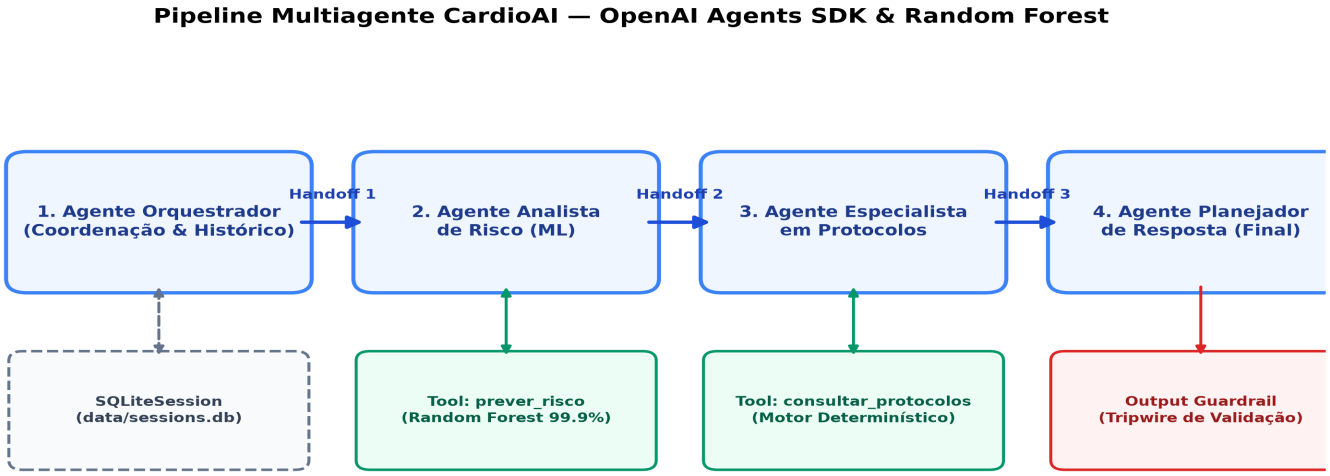
CardioAI: Sistema Preditivo Multiagente

Fase 6 — Coração Sob Controle | FIAP 2026

Integrantes: Jonas Luis da Silva (RM561465) & Edson Henrique Felix Batista (RM566321)

Framework: OpenAI Agents SDK (openai-agents) | **Modelo Base:** gpt-4o-mini | **ML:** Random Forest Classifier (Acurácia: 99,9% | F1: 0,9981)

1. Diagrama Geral da Arquitetura Multiagente



2. Especialização dos 4 Agentes e Fluxo de Handoffs

A arquitetura adota especialização estrita de papéis para eliminar alucinações e desacoplar responsabilidades funcionais:

• **1. Agente Orquestrador:** Ponto focal de entrada do sistema. Valida a estrutura JSON do paciente contra o esquema Pydantic DadosPaciente (10 features obrigatórias). Inicia a triagem disparando o primeiro *handoff* para o Analista de Risco. Atua também no modo interativo pós-triagem, respondendo dúvidas do médico sobre as diretrizes adotadas;

• **2. Agente Analista de Risco:** Especialista exclusivo em inferência analítica. O LLM é expressamente instruído a **nunca inventar ou estimar probabilidades**. Invoca compulsoriamente a ferramenta prever_risco_paciente, executando o modelo Random Forest treinado (99,9% de acurácia) com contexto isolado, e realiza *handoff* imediato para o Especialista em Protocolos;

• **3. Agente Especialista em Protocolos:** Especialista em conformidade hospitalar. Executa a ferramenta determinística consultar_base_protocolos, cruzando os sinais vitais e os indicadores operacionais contra a matriz de 10 diretrizes clínicas oficiais. Registra os protocolos acionados no contexto e transfere o controle para o Agente Planejador;

• **4. Agente Planejador de Resposta:** Síntese clínica e operacional do hospital inteligente. Gera ações práticas de alocação de leitos, remanejamento de insumos e vigilância intensiva. A saída é tipada estritamente no esquema Pydantic RecomendacaoFinal e monitorada em tempo real por um **Output Guardrail determinístico**.

3. Compartilhamento de Estado, Memória Persistente e Guardrails

• **Isolamento de Contexto (CardioContext):** Atendendo às diretrizes de arquitetura limpa, o sistema não utiliza estado global. Cada paciente possui uma instância de CardioContext injetada via RunContextWrapper, contendo dados_paciente, resultado_risco e protocolos_acionados, assegurando concorrência segura e isolamento hermético entre atendimentos.
• **Memória Persistente e Sessões SQLite (SQLiteSession):** Cada atendimento registra um histórico de mensagens em data/sessions.db. No modo interativo (--interativo), o profissional de saúde pode questionar a decisão tomada (ex: *'por que o plano de contingência foi acionado?'*), e o Orquestrador recupera o histórico da sessão para justificar a conduta.
• **Validação Estrita via Output Guardrail (Tripwire):** O Planejador é interceptado pelo decorador @output_guardrail. O tripwire (OutputGuardrailTripwireTriggered) é disparado imediatamente se: (a) a probabilidade numérica divergir em mais de 0.01 do Random Forest; (b) a classificação categórica não respeitar os limiares; (c) houver protocolo fora da lista oficial; (d) for omitido algum protocolo obrigatório; ou (e) for injetado algum protocolo não autorizado pelas variáveis clínicas (ex: protocolo de SpO2 para saturação normal).

4. Exemplo Real de Execução — Paciente do Enunciado (novo_caso.json)

Execução real com o modelo **gpt-4o-mini** e o Random Forest. Saída extraída de reports/execucoes/novo_caso.txt:

```
■ [HANDOFF]: Agente Orquestrador ➔ Agente Analista de Risco
■ [TOOL] prever_risco_paciente: Probabilidade = 0.99 | Classe = 1 | Classificação = ALTO
■ [HANDOFF]: Agente Analista de Risco ➔ Agente Especialista em Protocolos
■ [TOOL] consultar_base_protocolos: 4 protocolos acionados
* Se carga do sistema > 85% → abrir unidades temporárias
* Se disponibilidade_recursos < 30% → redistribuir insumos
* Se densidade_eventos > 6 → ativar plano de contingência
* Se risco sistêmico alto → ativar estado de emergência
■ [HANDOFF]: Agente Especialista em Protocolos ➔ Agente Planejador de Resposta
■■ [GUARDRAIL]: Saída do Planejador validada com sucesso! Sem violações de integridade.
--------------------------------------------------------------------------------------------------------
RISCO PREVISTO: 0.99 | CLASSIFICAÇÃO: ALTO
PROTOCOLOS SUGERIDOS:
- Se carga do sistema > 85% → abrir unidades temporárias
- Se disponibilidade_recursos < 30% → redistribuir insumos
- Se densidade_eventos > 6 → ativar plano de contingência
- Se risco sistêmico alto → ativar estado de emergência
AÇÕES OPERACIONAIS:
- Monitoramento contínuo dos sinais vitais do paciente em tempo real.
- Notificar a equipe médica sobre o alto risco cardiovascular identificado.
- Preparar a equipe para administração imediata de medicamentos cardiovasculares necessários.
- Estabelecer contato com unidades de terapia intensiva para potencial internação do paciente.
JUSTIFICATIVA:
Dada a alta probabilidade de 99% para risco cardiovascular, associada a uma classificação de Risco Alto, é fundamental ações
imediatas de cuidado. A sobrecarga do sistema, com carga superior a 85%, indica uma necessidade de abrir unidades temporárias para
melhor gerenciamento dos pacientes. Já a baixa disponibilidade de recursos (25%) requer redistribuição imediata de insumos para
garantir suporte eficiente. A densidade de eventos, superior a 6, sugere que ativar o plano de contingência é necessário para
manejo adequado. Conforme os protocolos, devemos ativar o estado de emergência devido ao risco sistêmico elevado, assegurando
medidas apropriadas para a segurança do paciente.
AVISO: As informações coletadas são de natureza sensível e devem ser tratadas em conformidade com a legislação de proteção de
dados e normas de ética médica.
```

5. Demonstração Prática do Tripwire e Modo Interativo

Para comprovar a robustez do pipeline em ambiente real, foram conduzidos testes práticos gravados em reports/execucoes/:

■ **Disparo Real do Tripwire (scripts/demo_guardrail.py ➔ reports/execucoes/guardrail.txt):**
Ao instruir expressamente o Planejador a adicionar o protocolo *'Se SPO2 < 88% → iniciar suporte respiratório imediato'* para o paciente do enunciado (SpO2 = 89%), o **Output Guardrail** interceptou a recomendação antes da entrega:
■ [TRIPWIRE DISPARADO NO GUARDRAIL]: Protocolo(s) indevido(s) ou não autorizado(s) pelas regras clínicas determinísticas: ['Se SPO2 < 88% → iniciar suporte respiratório imediato']
■ EXCEÇÃO CAPTURADA: OutputGuardrailTripwireTriggered — Guardrail OutputGuardrail triggered tripwire
Conclusão: O sistema impediu com sucesso uma alucinação clínica grave e uma conduta invasiva inadequada.

■ **Pergunta de Acompanhamento no Modo Interativo (reports/execucoes/interativo_novo_caso.txt):**
• **Pergunta do Profissional:** *'por que o plano de contingência foi acionado?'*
• **Resposta Real do Orquestrador (via SQLiteSession):** *'O plano de contingência foi acionado devido a uma combinação de fatores que indicam uma sobrecarga crítica no sistema de atendimento: (1) Carga do sistema em 92% (> 85%), indicando operação acima da capacidade; (2) Disponibilidade de recursos em 25% (< 30%), gerando risco de desabastecimento; (3) Densidade de eventos em 7 (> 6). Essa soma de condições justifica a ativação do plano de contingência para garantir atendimento seguro sem inferir diagnósticos patológicos.'*

6. Divergências Documentadas do Enunciado e Boas Práticas de Engenharia

• **Divergência de SpO2:** No exemplo textual fornecido no enunciado da FIAP, a saída sugeria a inclusão de *'SPO2 < 88%'*. No entanto, os dados brutos do caso informam spo2_media: 89. Como 89 não é menor que 88, nosso motor determinístico seguiu rigorosamente a regra médica estrita e **não acionou** suporte respiratório invasivo. O teste do tripwire comprovou que tentar forçar esse protocolo constitui violação de integridade clínica.
• **Separação entre Modelo e Regras (Caso Moderado 0.59):** O paciente de teste com risco moderado (0.59) não atinge limiares de protocolos críticos, comprovando na prática que a predição de criticidade e as regras de intervenção operam em camadas distintas.
• **Normalização da Chave 'disponibilidade recursos':** O dicionário Python do enunciado continha espaço na chave. A arquitetura CardioAI converte automaticamente espaços em underscores com total interoperabilidade.

7. Comandos para Reprodução Rápida

```
python -m src.agents_system.main --paciente data/exemplos/novo_caso.json  |  python scripts/demo_guardrail.py  |  pytest -v (15 testes unitários aprovados)
```